智护忆站：迁移学习与科研数据路线

以迁移学习为核心的研究与组织路线

2026-11-04

目录

摘要 1
1. 现状审计（代码事实） 2
2. 迁移学习怎么落到这个系统 3
  2.1 五条并行轨道 3
  2.2 先验迁移：把「权重研究」变成贝叶斯更新 3
  2.3 个体校准：混合效应模型，而不是「个性化 AI」 3
  2.4 设备域校准：配对测量是最便宜的办法 3
  2.5 量表链接：跨研究比较的关键一环 4
  2.6 表征迁移与深度学习：核心方法，分步落地 4
3. 科研检查清单（每次出数前必须过） 4
4. 数据收集体验：少打扰、按窗口、可核对 5
5. 运营台（/admin/）使用检查与微调 5
6. 置顶路线图（建议按此顺序） 6
7. 工程接入点（保持现有架构） 7
8. 组织与论文路线 7
9. 风险与红线 8

摘要

范围：在保持现有架构与成本可控的前提下，把迁移学习作为核心研究能力来建设：既支撑论文，也让 HPS 与照护负担评估具备可解释、可复现、可迁移的能力；同时改善数据收集体验与运营台可用性。

结论先行：

1. 迁移学习是本研究路线的核心能力，不是可选项：论文需要它，产品也需要它来解释「为什么一个新用户很快就能被理解」。
2. 迁移学习分五条并行轨道：**先验迁移、个体校准、设备域校准、表征迁移（含深度方法）、量表链接**。轻量轨道先交付，表征迁移同步准备。
3. 数据收集以「少打扰、按窗口、可核对」为原则；研究页直接给出下一次评估与一键进入，并围绕论文需要的锚点设计采集。

4. 组织路线与论文路线同步准备：角色、预注册、验证队列、可复现包与数据共享边界，缺一不可。

1. 现状审计（代码事实）

能力	现状	对研究的含义
评分	`hps-3`；`stress_score_events` 追加写，含 `params`、`coverage`、`algorithm_version`	历史分数可回放，满足可复现底线
缺失语义	缺指标不再补 0，`coverage` 标明缺失；无数据显示「数据不足」	避免假阴性；迁移模型也必须按缺失处理
标签	ZBI-12、PHQ-9、GAD-7；`assessments` 带 `date`	可按「用户 + 日期」与 HPS 配对
生理	手动录入可用；BLE 与原生桥只有契约，无真实设备	设备域迁移暂无数据，只能先做配对采集设计
研究入组	`studies` / `study_arms` / `study_enrollments` / `study_events`；按配比区组分配；评估窗口由 `schedule` 计算	已有分组与窗口，缺的是提醒与参与者级视图
数据导出	`research/dataset.mjs`：HMAC 去标识 CSV + `quality.json` + `manifest.json`；排除未同意、演示账号、`simulated` 与自由文本	可直接作为迁移实验的输入，但需补「版本冻结」
回放	`research/replay.mjs`：按事件快照与原始数据双重校验	迁移前后都必须过这一关
运营台	`/admin/`：概览、研究按臂质量、举报处置、配置校验与历史、导出命令	够用；缺参与者级钻取与导出留痕

结论：数据地基已具备「可复现 + 可去标识」；缺的是**用于迁移的配对样本与标签密度**，不是模型框架。

2. 迁移学习怎么落到这个系统

2.1 五条并行轨道

轨道	迁移什么	数据需求	成本	论文价值
先验迁移	文献/公开队列的效应量 → 本系统参数先验	无需本地大样本	低	方法学与敏感性分析
个体校准	群体模型 → 个体截距与斜率	每人 5–10 次锚点	低	个性化与校准曲线
设备域校准	手动↔蓝牙/健康 App 读数映射	20–30 次同窗配对	低	测量一致性与域适应
表征迁移	公开生理/文本表征 → 冻结特征 + 线性头	有一定标签量与设备数据	中	迁移学习主结果、消融
量表链接	ZBI-12 ↔ ZBI-22 等	双填或条目级数据	中	跨研究可比性

五条轨道共享同一份数据与评估协议；先交付前三条，表征迁移按实验计划推进。

2.2 先验迁移：把「权重研究」变成贝叶斯更新

- 目标：给 `hps_weights`、`level_thresholds` 设置**带不确定性的先验**，而不是拍一个 0.4/0.4/0.2。
- 做法：文献给出心理/生理分量的合理区间 → 形成先验；pilot 的锚定数据更新后验；输出后验均值与 95% 区间，直接写进论文方法。
- 交付物：`research/priors.json`（来源、区间、理由）+ 一页敏感性分析。

2.3 个体校准：混合效应模型，而不是「个性化 AI」

```
HPS_ij = β0 + β1·ZBI_ij + u0j + u1j·ZBI_ij + ε
u_j ~ N(0, Σ)  # 个体随机截距/斜率
```

- 群体部分从 pilot 估计；个体部分只需 5–10 个锚点即可收缩到稳定值。
- 新用户先走群体预测；锚点足够后再启用个体校准，并在 `stress_scores` 标注 `calibration_version`。
- 成本：统计脚本 + 导出字段，不需要在线推理服务。

2.4 设备域校准：配对测量是最便宜的办法

- 设计：要求设备用户每周做 1 次「手动 + 设备」同窗测量（相差 ≤10 分钟），形成配对样本。

- 模型：分指标的仿射映射（`y_manual = a·x_device + b`），带个体随机项；异常值用稳健回归。
- 验收：留一设备/留一用户交叉验证，MAE 与覆盖率同时报告；不达标就不启用设备分。
- 工程接口：`physio` 接入层已区分 `manual / ble / app-bridge`，配对只需要新增一个采集任务，不改造 HPS。

2.5 量表链接：跨研究比较的关键一环

- 同一批人同时填长短版，或拿到条目级数据，用等百分位链接或 IRT 链接。
- 输出映射表 + 置信区间，冻结版本；不要用回归硬拟合替代测量学链接。

2.6 表征迁移与深度学习：核心方法，分步落地

迁移学习是论文的核心特性，深度表征也在路线之内；要解决的是「怎么做才站得住」，而不是「要不要做」。

方法	适用场景	最低工程条件	交付
冻结特征 + 线性头	生理时序、文本检索	标签 ≥300 对；固定预处理	主结果 + 消融
轻量时序模型（TCN/GRU）	HRV/睡眠序列	设备数据连续、缺失可建模	对外部队列验证
表格基础模型/先验网络	小样本回归/分层	严格交叉验证、校准评估	与线性基线对比
文本表征迁移	知识检索、问答召回	中文 embedding、离线索引	不参与诊断输出

数据与验证要求（是执行计划，不是禁止条款）：标签量与缺失率足以支撑交叉验证；有独立时间段或第二队列做外部验证；预注册主指标；模型卡记录训练数据版本与失败模式。

工程形态：离线训练（Python/Notebook），导出 ONNX/TFLite；推理优先服务端批处理；pilot 阶段不引入在线 GPU。产物包括模型卡、数据 manifest、复现脚本与失败分析。

组织准备：数据管理员负责版本与脱敏；研究分析负责预注册与统计；工程负责训练/推理与回放；PI 负责临床解释与论文叙事。四条线并行，避免「模型先行、数据返工」。

3. 科研检查清单（每次出数前必须过）

检查	判定	现有工具
同意与排除	仅纳入已同意、未撤回；排除演示与 `simulated`	`dataset.mjs` 默认规则
去标识	HMAC 用户 ID；密钥不入库	`RESEARCH_HMAC_SECRET`

检查	判定	现有工具
时间对齐	量表与 HPS 同日/同窗才配对；跨日不混	`assessments.date` + 事件时间
缺失处理	不零填充；按 `coverage` 分层或插补	评分快照 `coverage`
可复现	任一历史分数可由快照与原始数据重算	`replay.mjs` 双校验
版本	数据集带 `manifest.json`（时间、规则、数量、哈希）	`dataset.mjs`
泄漏	训练/验证按用户或时间切分，不随机拆同日记录	实验脚本
预注册	主指标、样本量、敏感性分析先写后跑	研究方案

验收底线：回放不一致（退出码 1）时，这批数据不得进入建模或论文。

4. 数据收集体验：少打扰、按窗口、可核对

1. **研究页直接给下一步**：显示下一次评估窗口、量表清单、截止时间，并提供「去做第 N 天评估」按钮（本轮已在「我的 - 研究参与」加入）。窗口开放或过期都可一键进入，减少找不到入口造成的缺失。
2. **打卡一屏完成**：保持默认值预填、滑杆与数字键盘，不强制填写备注；生理数据标为可选。
3. **配对测量任务**：设备接入后，按周生成一次「手动 + 设备」任务，完成即形成迁移样本。
4. **缺失可解释**：界面明确显示「数据不足」而不是绿色；研究招募与知情同意中说明缺测不影响照护使用。
5. **退出必填原因**：退出研究时收集 1 个原因码（时间不够/不适/隐私/其他），用于流失分析。
6. **提醒**：仅围绕评估窗口发送一次提醒（站内 + 可选微信），不做高频推送。

5. 运营台（/admin/）使用检查与微调

已合理：概览、按臂质量、举报处置（必填理由）、配置校验与历史、导出命令、备份列表；写操作走服务端路由，避免第二套权限。

仍不合理/缺口：

缺口	影响	低成本改法
只有按臂聚合，没有参与者列表	无法定位谁缺评估、谁该提醒	研究详情加「参与者」只读表（匿名 ID、入组日、打卡天数、评估次数、最近窗口状态）

缺口	影响	低成本改法
退出原因未结构化	流失分析只能靠猜	退出接口增加 `reason` 枚举与自由文本，写入 `study_events`
导出命令靠复制	易漏参数、版本不可追溯	后台生成带时间戳的导出任务，记录操作者与 manifest 哈希
角色只有超管	导师/合作者只能给超管	增加只读研究角色（最小权限），写操作仍限超管
配置变更无差异视图	只能看历史值	历史行展示 before/after 与作者、理由

6. 置顶路线图（建议按此顺序）

优先级	事项	交付	验收	预估
P0	数据卫生与研究页 CTA	研究页下一次评估入口；退出原因；回放纳入 CI	窗口可见可点；回放 0 退出码	3–5 天
P1	先验迁移	`priors.json` + 贝叶斯更新脚本 + 敏感性分析	后验区间可复现；专家签字	1–2 周
P1	表征迁移基线	冻结特征 + 线性头 + 消融	与线性基线对比、校准指标	2–3 周
P1	参与者级运营视图	研究详情参与者表 + 导出任务记录	一键定位缺测用户	3–5 天
P2	个体校准 pilot	混合效应模型 + `calibration_version`	LOSO 验证 MAE/校准斜率改善	2–3 周
P2	设备配对采集	配对任务 + 仿射校准脚本	20–30 对样本，留一验证	设备到位后 2 周
P2	深度时序/表格模型	轻量模型 + 外部验证	第二队列验证通过	4–6 周

优先级	事项	交付	验收	预估
P3	量表链接	映射表 + 版本冻结	跨批次可比性报告	2 周
P3	组织与论文包	预注册、SAP、模型卡、复现包	可提交的论文材料	持续

成本口径：一名工程师 + 一名研究分析，合计约 6–8 人周；不新增服务器与第三方服务。

7. 工程接入点（保持现有架构）

- 导出：沿用 `research/dataset.mjs`；新增 `research/transfer/` 下的先验、校准、评估脚本，只读同一份 CSV + manifest。
- 评分：迁移结果以 `calibration_version`、`params` 写回 `stress_scores`，仍走事件追加，不回填历史。
- 设备：沿用 `lib/physio` 的 `source` 与 `ingestPhysio`；配对样本作为一次普通采集，不新建表。
- 运营：仅补只读聚合与导出记录，不新增可写入口。

8. 组织与论文路线

角色	负责	产出
PI / 临床	研究问题、量表选择、临床解释	预注册、论文叙事、伦理材料
研究分析	方案、统计、校准与外部验证	SAP、分析代码、结果表
工程	采集、导出、训练/推理、回放	数据管道、模型服务、可复现包
数据管理员	同意、脱敏、版本、共享边界	manifest、数据字典、访问记录

论文路线（与产品并行）：

1. 预注册：主问题（迁移是否改善校准/误差）、主指标、样本量、敏感性分析。
2. 数据冻结：manifest 哈希 + 回放全绿才进入分析。
3. 主分析：群体基线 vs 先验迁移 vs 个体校准 vs 表征迁移；报告 MAE、校准斜率/截距、Brier、分层稳定性。
4. 外部验证：第二队列或后一时间窗；失败也要报告。
5. 可复现包：数据字典、脚本、环境、模型卡；按同意范围共享。

组织节奏：每两周一次数据评审；每月一次论文/产品联合评审；所有变更写入研究事件与 manifest。

9. 风险与红线

- 不得把 `simulated`、演示账号、未同意数据混入训练或论文。
- 不得用零填充缺失分量；不得用干预次数当压力特征。
- 不得在 n<100 时宣称「个性化 AI」；对外表述为「群体先验 + 个体校准」。
- 任何迁移上线前必须过回放与预注册；不一致就停。

一句话：先把「可复现的数据 + 按窗口的标签 + 配对样本」做扎实，迁移学习才有意义；这三件事都不需要大模型。